# INFO 5 – Projet 1 : Analyse mathématique et statistique de textes

*Niveau : L1 Maths | Séance 3 sur 4 (3h)*

### Objectifs de la séance

- Comprendre et implémenter des distances mathématiques dans un espace de dimension 26.
- Comparer des textes en calculant la distance entre leurs vecteurs de fréquences.
- Utiliser la structure de données `set` (ensemble) en Python.
- Implémenter l'indice de similarité de Jaccard pour comparer des ensembles de bigrammes.

---

## Partie 1 : Espaces métriques et distances classiques

Lors de la première séance, nous avons modélisé un texte par un vecteur de fréquences de dimension 26. Soient deux textes $A$ et $B$, de vecteurs respectifs $U = (u_0, \ldots, u_{25})$ et $V = (v_0, \ldots, v_{25})$. Pour déterminer si deux textes se ressemblent (ou sont écrits dans la même langue), nous allons calculer la "distance" mathématique entre leurs vecteurs.

### Exercice 1 : Distance de Manhattan (Norme $L_1$)

La distance de Manhattan correspond à la somme des écarts absolus coordonnée par coordonnée.

$$d_1(U, V) = \sum_{i=0}^{25} |u_i - v_i|$$

```python
def distance_manhattan(freq1, freq2):
    """Calcule la distance L1 entre deux vecteurs de frequences."""
    distance = 0.0

        # La fonction abs() calcule la valeur absolue en Python

    return distance
```

### Exercice 2 : Distance Euclidienne (Norme $L_2$)

La distance euclidienne est la distance géométrique classique (généralisation du théorème de Pythagore).

$$d_2(U, V) = \sqrt{\sum_{i=0}^{25} (u_i - v_i)^2}$$

```python
import math

def distance_euclidienne(freq1, freq2):
    """Calcule la distance L2 entre deux vecteurs de frequences."""
    somme_carres = 0.0

        # En Python, l'elevation a la puissance se fait avec **


    return
```

---

## Partie 2 : Théorie des ensembles et Indice de Jaccard

Plutôt que d'étudier les fréquences, nous pouvons étudier le vocabulaire d'un texte. Un texte peut être vu comme un **ensemble** (au sens mathématique) de mots ou de bigrammes.

En Python, la structure `set` modélise parfaitement les ensembles mathématiques : elle ne contient pas de doublons et permet des opérations rapides comme l'intersection ($\cap$) et l'union ($\cup$).

### Exercice 3 : Extraire l'ensemble des bigrammes

Complétez la fonction pour extraire tous les bigrammes uniques d'un texte.

```python
def extraire_bigrammes_uniques(texte_propre):
    """Renvoie un ensemble (set) contenant les bigrammes uniques du texte."""
    # Initialisation d'un ensemble vide
    bigrammes = set()


        # Extraction de la paire de lettres


        # Ajout a l'ensemble (les doublons sont ignores automatiquement)
        bigrammes.add(________)

    return bigrammes
```

### Exercice 4 : Indice de similarité de Jaccard

L'indice de Jaccard $J(A, B)$ mesure la similarité entre deux ensembles $A$ et $B$. Il vaut 1 si les ensembles sont identiques, et 0 s'ils sont disjoints.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

où $|X|$ représente le cardinal (nombre d'éléments) de l'ensemble $X$.

En Python, pour deux ensembles `A` et `B` :

- L'intersection s'obtient avec `A.intersection(B)` (ou `A & B`).
- L'union s'obtient avec `A.union(B)` (ou `A | B`).
- Le cardinal s'obtient avec `len(A)`.

```python
def indice_jaccard(ensemble_A, ensemble_B):
    """Calcule l'indice de Jaccard entre deux ensembles."""
    # Cas limite : si les deux ensembles sont vides, ils sont identiques


    # 1. Calcul de l'intersection et de l'union


    # 2. Application de la formule du cardinal


    return jaccard

# Question : La "distance" de Jaccard est definie par d = 1 - J(A, B).
# Si J(A, B) = 0.8, que cela signifie-t-il vis-a-vis de la distance entre A et B ?
```

---

## Partie 3 : Application – Détection de la langue

Vous disposez des fréquences théoriques d'apparition des lettres en Français et en Anglais (que vous trouverez sur internet ou calculerez sur un gros corpus). Écrivez un script principal qui :

1. Lit un texte mystère depuis un fichier `mystere.txt`.
2. Normalise le texte et calcule son vecteur de fréquences.
3. Calcule la distance (Manhattan ou Euclidienne) entre ce texte et le profil du Français, puis avec le profil de l'Anglais.
4. Affiche la langue détectée (celle dont la distance est la plus petite).